

Ouvidoria Inteligente

Triagem semântica de manifestações cidadãos


Escopo e procedência dos dados

A solução reúne análise de representações, detecção de duplicatas, tratamento de textos longos e aplicativo Streamlit. A base oficial mencionada no enunciado não foi disponibilizada. Foi utilizada, com autorização, uma base demonstrativa sintética de 40 manifestações anônimas fictícias, distribuídas entre infraestrutura, saúde, segurança, educação e meio ambiente. Nenhum resultado deve ser interpretado como retrato de uma prefeitura real.

Há seis pares rotulados de duplicatas: seis registros reformulam seis anteriores, correspondendo a 15% do corpus. O gabarito foi definido na construção da base e não pelo modelo. Os cinco maiores textos têm mais de 500 caracteres. Adotou-se esse critério porque o enunciado alterna entre caracteres e palavras. Os pares exigidos mantêm seus temas e IDs, mas os textos não são os da base oficial.

Representações comparadas


BoW e TF-IDF foram calculados com tokenização padrão do scikit-learn. Os modelos densos são paraphrase-multilingual-MiniLM-L12-v2 e distiluse-base-multilingual-cased-v2, ambos multilíngues. Usou-se cosseno em todas as representações; para vetores densos normalizados, o produto escalar é equivalente.



BoW depende de vocabulário compartilhado; TF-IDF reduz o peso de termos frequentes, mas pode valorizar demais nomes próprios raros. Embeddings capturam paráfrases, porém proximidade temática não garante mesmo evento. Os escores não são probabilidades e não devem ser comparados como medidas calibradas entre modelos. A tabela completa dos três pares consta no notebook e no CSV.

Duplicatas e escolha do limiar

Foi adotado inicialmente cosseno maior que 0,85. No corpus sintético, o resultado foi 4 verdadeiros positivos, 0 falsos positivos e 2 falsos negativos, com precisão 100.0% e recall 66.7%. A função remove a diagonal e considera apenas i menor que j , evitando duplicação dos pares.



O notebook apresenta todos os erros com os textos correspondentes. Um falso positivo pode compartilhar tema e vocabulário sem ser o mesmo evento; um falso negativo pode reformular demais o relato para ultrapassar o limiar. A análise de sensibilidade entre 0,65 e 0,95 mostra o compromisso entre precisão e recall. Escolher o melhor limiar nessa mesma amostra não constitui validação independente.


Em produção, seriam necessários pares rotulados de outro período, exemplos difíceis, checagem de local e tempo e revisão humana para casos limítrofes. O gabarito desta base não pode ser reutilizado na avaliação de um arquivo oficial diferente.

Chunking e preservação do contexto

RecursiveCharacterTextSplitter foi aplicado aos cinco textos mais longos com 250/0, 250/50 e 400/80 caracteres de tamanho/overlap. As duas primeiras configurações isolam o efeito do overlap; a terceira avalia blocos maiores. Foram registrados textos dos chunks, quantidades, tamanhos e cosseno médio entre vizinhos.

Recomenda-se 400/80 para estes relatos: blocos maiores mantêm mais relações entre problema, localização e solicitação. Em M036, por exemplo, a descrição liga drenagem, invasão das casas, dificuldade de locomoção e pedido de vistoria. O notebook mostra os cortes nas três configurações para inspeção direta. O overlap reduz perda de contexto nas fronteiras, mas também repete palavras, aumenta custo e pode elevar artificialmente a similaridade.

Neste experimento, 250/0 e 250/50 geraram exatamente os mesmos chunks e escores. Os segmentos por sentença excederam a janela de 50 caracteres, impedindo sobreposição efetiva. Portanto não houve ganho observado ao aumentar esse parâmetro para 50; o efeito teórico depende das fronteiras escolhidas pelo splitter.



Com 400/80, a similaridade média entre chunks da mesma manifestação foi 0.549; entre manifestações diferentes, 0.367. Essa medição no espaço original complementa a PCA. Proximidade visual não é prova de coerência e nem todo chunk de um mesmo relato precisa tratar do mesmo subtema.

Aplicativo e organização

O Streamlit contém Busca Semântica, Base Completa, Espaço Vetorial e Chunking. A busca exibe por padrão cinco manifestações, cosseno e cores nos intervalos exigidos: verde acima de 0,7, amarelo acima de 0,5 e vermelho nos demais. A barra lateral permite escolher entre os dois modelos e configurar top-k. A base completa pode gerar a matriz de similaridade. PCA e t-SNE são selecionáveis.

A aba Chunking recebe texto livre, estratégia e parâmetros, exibindo trechos, vetores e projeção. O modelo usa cache de recurso e os embeddings usam cache de dados. Funções comuns em ouvidoria.py garantem consistência entre notebooks e interface. O README descreve instalação, execução, origem dos dados e publicação em Git.

Categorias e espaço vetorial

A silhouette de categorias no espaço original, usando distância de cosseno e o primeiro modelo, foi 0.136. Categorias foram usadas apenas como rótulos de avaliação e cor. Textos de saúde, por exemplo, compartilham contexto, mas podem descrever falta de medicamento, agendamento ou acessibilidade. Categorias administrativas não são necessariamente grupos semânticos bem separados. PCA e t-SNE fornecem vistas complementares, com distorções diferentes.

Dificuldades e aprendizados

A ausência da base oficial limita a comparabilidade da entrega. Uma base sintética permite reproduzir testes, mas pode favorecer paráfrases evidentes. A normalização dos embeddings simplifica o cálculo do cosseno; a inspeção dos erros mostra por que semelhança e duplicidade não são equivalentes. O teste de chunking evidencia a troca entre contexto preservado, redundância e custo.

A busca atual classifica manifestações completas. Para documentos maiores que o limite de tokens do encoder, recomenda-se indexar chunks e agregar resultados por manifestação, em vez de depender de truncamento. Os limites em caracteres do splitter não garantem um número exato de tokens. O modelo não deve decidir automaticamente sobre prioridade ou validade de uma denúncia.

Reprodutibilidade e validação

Os três notebooks contêm execução real, tabelas e gráficos. Testes cobrem base, limiar estrito, pares únicos, textos vazios, limites do splitter e projeção de amostra pequena. Modelos requerem download inicial e não vão para o Git. A entrega inclui requisitos de instalação, CSVs e gabarito. Ao receber dados oficiais, é necessário reexecutar tudo e reescrever as conclusões afetadas.

Referências técnicas

Enunciado Desafio Ouvidoria Inteligente. Reimers e Gurevych (2019), Sentence-BERT. Sentence Transformers: <https://www.sbert.net/> . LangChain text splitters: <https://docs.langchain.com/oss/python/integrations/splitters/> . scikit-learn: <https://scikit-learn.org/> .